

PIPELINE

Clean & normalize text
(lowercase, ลบวงเล็บ/หน่วย, แก้คำซ้ำ)

1

แยกคำศัพท์หมวด drug, disorder, finding และ procedure ด้วย semantic tag เพื่อการเลือกใช้ category ที่ถูกต้อง

2

สร้างSNOMED-CT (term_norm) เป็น embedding vector เพื่อใช้คำนวณ similarity

3

4

สร้าง Faiss Index เพื่อสร้างโครงสร้างข้อมูลสำหรับค้นหา nearest neighbor

5

คำนวณ similarity เพื่อตรวจสอบความแม่นยำของการแมปคำ โดยใช้ dot product (inner product) ระหว่างเวกเตอร์

MODEL

SAPBERT

"bert-base-uncased"

BIOBERT

"pritamdeka/BioBERT-mnli-
snli-scinli-scitail-mednli-
stsb"

AVERAGE SIMILARITY SCORE

● BioBERT ● SapBERT

